

머신러닝 및 딥러닝 핵심 개념 가이드

1. 머신러닝과 딥러닝의 주요 차이점

머신러닝(Machine Learning)과 딥러닝(Deep Learning)의 가장 본질적인 차이는 '특성 추출(Feature Extraction)'의 주체와 '데이터 의존성'에 있습니다.

- 특성 추출의 자동화:** 머신러닝은 전문가가 직접 데이터의 유의미한 특징을 정의해야 하지만, 딥러닝은 신경망이 데이터로부터 스스로 특징을 찾아냅니다.
- 데이터 및 컴퓨팅 자원:** 딥러닝은 대규모 데이터와 GPU 같은 고성능 하드웨어가 필수적이거나, 머신러닝은 상대적으로 적은 데이터와 CPU만으로도 효과적인 모델 생성이 가능합니다.

1) 가장 결정적인 차이: 특성 추출 (Feature Extraction)

- 가장 핵심이 되는 포인트입니다.
 - 머신러닝:** 사람이 데이터의 특징을 직접 골라줘야 합니다. 예를 들어 자동차를 인식시킨다면, 사람이 "바퀴가 있고, 유리창이 있고, 크기는 이 정도야"라고 핵심 특징(Feature)을 정의해서 컴퓨터에게 넘겨줍니다.
 - 딥러닝:** 데이터만 대량으로 넣어주면, 컴퓨터(신경망)가 스스로 데이터에서 특징을 찾아냅니다. "아, 이런 형태와 선들이 모이면 자동차구나"라는 것을 층(Layer)을 거치며 직접 학습합니다.

2) 데이터 양과 하드웨어의 의존도

- 데이터 양:**
 - 머신러닝:** 비교적 적은 양의 데이터로도 훌륭한 성능을 낼 수 있습니다. 오히려 데이터가 너무 적을 때는 딥러닝보다 효율적입니다.
 - 딥러닝:** 데이터가 많으면 많을수록 성능이 기하급수적으로 좋아지지만, 데이터가 부족하면 제대로 학습되지 않습니다.
- 하드웨어:**
 - 머신러닝:** 일반적인 고성능 CPU만으로도 충분히 학습과 실행이 가능합니다.
 - 딥러닝:** 복잡한 행렬 연산이 필수적이라 **GPU(그래픽 카드)** 성능이 매우 중요합니다.

3) 문제 해결 방식 (과정의 차이)

구분	머신러닝 (ML)	딥러닝 (DL)
해결 방법	문제를 여러 부분으로 쪼개서 각각 해결 후 합침	문제를 끝에서 끝까지(End-to-End) 통째로 학습
실행	학습 시간은 짧지만, 특징	학습 시간은 매우 길지만, 특징 추출

• 구분	• 머신러닝 (ML)	• 딥러닝 (DL)
시간	추출에 공이 많이 들어감	자동화
• 해석 가능성	• 결과가 왜 나왔는지 논리적으로 설명하기 쉬움	• 내부가 복잡하여 왜 그런 결과가 나왔는지 설명하기 어려움 (Black Box)

2. 사이킷런(Scikit-learn)과 텐서플로우(TensorFlow)의 차이

두 라이브러리는 해결하고자 하는 문제의 복잡도와 데이터의 성격에 따라 선택이 달라집니다.

구분	사이킷런 (Scikit-learn)	텐서플로우 (TensorFlow)
주요 영역	전통적 머신러닝 알고리즘	인공신경망 및 딥러닝
데이터 종류	정형 데이터 (표, 엑셀)	비정형 데이터 (이미지, 영상, 음성)
장점	사용이 간편하고 해석이 용이함	복잡한 패턴 인식 및 확장성 우수
하드웨어	CPU 중심	GPU / TPU 지원

1) 사이킷런 (Scikit-learn)

"전통적인 머신러닝의 표준"

데이터 분석과 통계적 머신러닝을 위한 가장 대중적인 라이브러리입니다.

주요 용도: 분류, 회귀, 클러스터링, 차원 축소, 전처리(Scaling, Encoding).

대표 알고리즘: SVM, Random Forest, Gradient Boosting, k-Means, PCA 등.

장점:

사용성: API가 매우 직관적입니다. fit()과 predict() 두 가지만 알면 거의 모든 모델을 학습시킬 수 있습니다.

완결성: 데이터 전처리부터 모델 평가까지 파이프라인 구축이 매우 편리합니다.

가벼움: CPU 기반에서도 빠르게 동작하며 데이터 양이 아주 방대하지 않을 때 효율적입니다.

단점: 딥러닝(신경망) 기능이 매우 제한적이며, GPU 가속을 기본적으로 지원하지 않습니다.

2) 텐서플로우 (TensorFlow / Keras)

"딥러닝과 대규모 생산을 위한 플랫폼"

구글에서 만든 라이브러리로, 복잡한 신경망 구조를 설계하고 대규모 데이터를 처리하는 데 특화되어 있습니다.

주요 용도: 이미지 인식(CNN), 자연어 처리(RNN, Transformer), 생성 모델(GAN), 강화 학습.

장점:

유연성: 아주 복잡한 층(Layer) 구조를 사용자가 직접 설계할 수 있습니다.

확장성: GPU나 TPU를 활용한 병렬 연산이 가능하여 거대 모델 학습에 유리합니다.

생태계: 모바일(TF Lite), 웹(TF.js), 서버 배포(TF Serving) 등 상용화 환경으로의 배포 도구가 강력합니다.

단점: 사이킷런에 비해 학습 곡선이 높고, 코드 양이 많으며 단순한 통계 모델을 만들기에는 과한 면이 있습니다.

비교 항목	사이킷런 (Scikit-learn)	텐서플로우 (TensorFlow)
데이터 종류	정형 데이터 (엑셀, DB 표 형태)	비정형 데이터 (이미지, 음성, 텍스트)
핵심 기술	전통적 알고리즘 (SVM, 트리 모델 등)	인공신경망 (Deep Learning)
하드웨어	주로 CPU	GPU / TPU 필수 권장
난이도	낮음 (입문자 친화적)	보통 ~ 높음

3. 서포트 벡터 머신 (Support Vector Machine)

SVM은 서로 다른 클래스를 구분하는 '최적의 초평면(Hyperplane)'을 찾아 마진(Margin)을 최대화하는 알고리즘입니다.

1) 핵심 개념: 초평면과 마진

SVM의 목표는 두 데이터를 갈라놓는 여러 직선(또는 평면) 중에서, 두 집단 사이의 거리를 최대한 멀리 떨어뜨리는 결정 경계를 찾는 것입니다.

초평면(Hyperplane): 데이터를 나누는 결정 경계입니다. 2차원에서는 직선, 3차원에서는 평면의 형태가 됩니다.

서포트 벡터(Support Vector): 결정 경계에 가장 가까이 붙어 있는 데이터 포인트들을 말합니다. 이 포인트들이 경계를 지지(Support)하고 있기 때문에, 이들의 위치가 변하면 결정 경계도 변하게 됩니다.

마진(Margin): 결정 경계와 서포트 벡터 사이의 거리를 뜻합니다. SVM은 이 마진을 최대화(Maximize)하는 것을 목표로 합니다.

2) SVM의 주요 특징

커널 트릭 (Kernel Trick)

데이터가 직선으로 도저히 나눌 수 없는 복잡한 형태일 때, 데이터를 더 높은 차원으로 보내서 평면으로 나눌 수 있게 만드는 기법입니다.

선형(Linear) 커널: 직선으로 분류 가능할 때 사용합니다.

RBF(가우시안) 커널: 복잡한 곡선 형태의 경계가 필요할 때 주로 사용하며, 실무에서 가장 인기가 많습니다.

다항식(Polynomial) 커널: 데이터의 특성을 조합해 고차원적인 관계를 파악합니다.

하드 마진 vs 소프트 마진

하드 마진(Hard Margin): 오차를 절대 허용하지 않는 방식입니다. 데이터에 노이즈가 많으면 모델을 만들기 어렵거나 과적합(Overfitting)될 위험이 큼니다.

소프트 마진(Soft Margin): 약간의 오차(잘못 분류된 데이터)를 허용하면서 마진을 크게 가져가는 방식입니다. 실무에서는 보통 일반화 능력을 높이기 위해 소프트 마진을 선호합니다.

3) 왜 SVM을 사용할까요?

정확도: 데이터의 차원이 높아도(변수가 많아도) 꽤 안정적인 성능을 보여줍니다.

효율성: 전체 데이터가 아니라 서포트 벡터들만 사용하여 경계를 결정하므로 메모리 관리가 효율적입니다.

과적합 방지: 마진을 최대화하기 때문에 새로운 데이터가 들어왔을 때도 틀릴 확률이 상대적으로 낮습니다.

4. 선형 및 비선형 환경에서의 활용

SVM은 데이터의 분포에 따라 두 가지 방식으로 활용됩니다.

1. **선형(Linear) SVM:** 데이터가 직선이나 평면으로 명확히 나누어질 때 사용하며, 모델이 단순하고 계산이 빠릅니다.
2. **비선형(Non-linear) SVM:** 커널 트릭(Kernel Trick)을 사용하여 저차원 데이터를 고차원으로 매핑함으로써, 복잡한 곡선 형태의 경계를 생성하여 데이터를 분류합니다.

구분	선형 SVM	비선형 SVM
데이터 형태	직선/평면으로 구분 가능	복잡한 곡선/경계 필요
핵심 기술	하드/소프트 마진 최적화	커널 트릭 (RBF, Polynomial 등)
장점	학습 속도가 매우 빠름	복잡한 패턴을 정교하게 학습함
단점	복잡한 데이터 분리에 한계	파라미터 설정이 까다롭고 과적합 주의