

생성형 AI 프로젝트 계획서

1. 팀의 목표 정리

단순히 모델을 만드는 것을 넘어, 한국어 특화 미니 GPT 를 구현하고 실험적 성능 검증까지 하는 것을 목표로 한다.

이후 실사용(챗봇, 번역, 요약 등)으로 확장 가능성을 고려한다.

2. 프로젝트 개요

- 프로젝트명: 한국어 미니 GPT 개발
- 목표:
 - 한국어 특화된 소형 GPT 모델을 개발
 - 대화, 요약, 번역 등 기본적인 자연어 생성(NLG) 기능을 실현
 - 연구/실험 환경에서 활용 가능하며, 추후 확장성을 고려

3. 팀 구조 제안

- 데이터팀: 말뭉치 수집·전처리 (웹 크롤링, 토큰화, 클리닝, 학습 데이터셋 준비).
- 모델팀: Transformer 구조 설계 및 구현 (TensorFlow/PyTorch 기반).
- 학습팀: 학습 환경 구성 (GPU 세팅, 분산 학습, 실험 관리).
- 응용팀: 학습된 모델을 API·웹 서비스로 연결 (예: Flask, FastAPI, React 등).
- 평가팀: 모델 성능 평가 (BLEU, Perplexity, 사용자 평가 등).

3. 리더로서의 역할

- 프로젝트 로드맵 수립.
- 각 팀에 가이드 문서와 교육자료 제공.
- 주간 미팅을 통해 진행 상황 점검 및 병목 해결.
- 연구 방향과 결과를 정리해 보고서 작성.

4. 개발 범위

4-1. 데이터 수집 및 전처리

- 한국어 말뭉치 확보 (뉴스, 위키, SNS 등 공개 데이터)
- 클리닝, 불필요한 특수문자 제거
- 토큰나이저 적용 (SentencePiece, BPE)

4-2. 모델 설계 및 학습

- Decoder-only Transformer 구조 설계
- 모델 크기: 50M ~ 150M 파라미터 (소형 GPT)
- 학습 프레임워크: TensorFlow 또는 PyTorch
- GPU 분산 학습 환경 구성

4-3. 응용 및 배포

- REST API 구축 (Flask 또는 FastAPI)
- 웹 UI(React 기반)에서 질의응답/대화 테스트

- 모델 추론 속도 최적화

4-4. 평가 및 고도화

- 평가 지표: Perplexity, BLEU, Rouge
- 사용자 테스트: 간단한 QA, 번역, 요약 성능 확인
- Fine-tuning 으로 특정 도메인 확장 가능성 검토

5. 모델 설계 및 학습 내용

- 모델 구조: Decoder-only Transformer 구조를 처음부터 직접 코드로 구현
셀프-어텐션 메커니즘, 포지셔널 인코딩, 레이어 정규화, 피드포워드 신경망 등 모든 구성 요소를 수작업으로 작성.
- 데이터 전처리: 대규모 텍스트 데이터를 토큰화하고, 모델이 이해할 수 있는 숫자 형태로 변환하는 전처리 파이프라인을 직접 구축.
여기에는 BPE(Byte-Pair Encoding)나 SentencePiece와 같은 토큰라이저를 사용해야 하는데, 이 또한 직접 구현하거나 외부 라이브러리를 사용
- 훈련 루프: 모델을 훈련시키기 위한 훈련 루프(training loop)를 직접 작성
옵티마이저 설정, 손실 함수 정의, 그래디언트 계산, 모델 파라미터 업데이트 등 단계가 포함.
- 추론 및 디코딩: 훈련된 모델을 사용하여 새로운 텍스트를 생성하는 추론(inference) 과정도 직접 구현.

특히, 대화형 GPT 모델의 경우 “그리디 서치(greedy search) 또는 빔 서치(beam search)”와 같은 텍스트 디코딩 전략을 구현

6. 팀 구조 보강안

6-1, 데이터팀

- 기존 역할: 말뭉치 수집·전처리
- 보강 역할: 데이터베이스(DB) 구축 및 관리 (수집 데이터 저장, 버전 관리, 검색 기능 제공)

인프라팀 (신규)

- 역할: GPU 클러스터 및 클라우드 자원 관리, 데이터베이스 서버 운영, 실험 환경 자동화
학습팀과 협력하여 안정적인 학습 및 서비스 환경 제공

6-2. 서비스 단계 고려

- 사용자 대화 로그 및 피드백 데이터를 데이터베이스에 저장하여, 향후 모델 파인튜닝 및 성능 개선에 활용
- 학습 결과 및 메트릭 기록 (DB 기반 실험 관리: MLflow, W&B 등 활용 가능)

7. 기대 효과

- 한국어 특화 소형 GPT 모델 확보
- 오픈소스 수준의 실험 환경 구축
- 대화/요약/번역 등 다양한 NLG 응용 가능
- 추후 대규모 모델 확장 및 서비스화 가능

8. 향후 발전 방향

- 대규모 GPU 클러스터 기반 학습 확장

- 도메인 특화 Fine-tuning (법률, 의료, 쇼핑 등)

- 멀티모달(텍스트+이미지) 모델 확장